

터보 오토인코더의 성능 분석

김정현, 임수빈, 이한별

순천향대학교

kimjh@sch.ac.kr, qlstn9150@gmail.com, 99dlgksquf@naver.com

Performance analysis of Turbo Autoencoder

Junghyun Kim, Subeen Leem, Hanbyul Lee

Soonchunhyang Univ.

요약

본 논문은 딥러닝 모델의 하나인 오토인코더 기반의 터보 오토인코더의 성능 분석을 다룬다. 기존의 터보 오토인코더 구조를 개선하여 향상된 성능을 갖는 딥러닝 모델을 제안한다. 실험을 통해 제안한 터보 오토인코더가 기존 터보 오토인코더보다 더 낮은 블록 오류율 및 비트 오류율을 가짐을 보였다. 제안한 기법을 통해 향후 추가적인 모델 개선에 대한 방향성을 제시한다.

I. 서론

최근 인공지능을 활용한 오류정정부호 기법이 다양하게 제안되고 있다. 부호 설계 기법으로는 강화학습 기반의 LDPC 부호 설계[1]와 Polar 부호 설계[2] 등이 제안되었고, 복호기 설계 기법으로는 RNN 구조를 갖는 Convolutional 부호의 복호기[3]와 Block 부호의 복호기[4] 등이 제안되었다. 또한 LDPC 부호의 순차적 복호기를 설계하기 위해 멀티 암드 밴딧(Multi-Armed Bandits) 문제로 접근한 기법[5]이 있다.

오류정정부호의 부호기와 복호기를 동시에 설계하는 딥러닝 기반의 기법으로 오토인코더를 활용한 기법[6]이 있다. 오토인코더는 신경망 구조를 사용한 비선형 주성분 분석의 한 기법으로 제안된 딥러닝 모델이다. 특히 잡음 제거 오토인코더는 잡음이 존재하는 데이터로부터 추출된 데이터 고유의 특징을 이용하여 데이터 내의 잡음을 제거할 수 있다. 그러나 긴 길이의 부호를 완전 연결층으로 구성된 오토인코더로 설계 시 학습 시간이 매우 오래 걸릴 뿐만 아니라 신경망의 가중치가 글로벌 최적값으로 수렴하지 못하는 한계가 존재한다.

이러한 한계를 극복하기 위하여 기존 터보 부호의 구조를 활용하여 인터리버가 포함된 신경망 구조를 설계함으로써 학습 파라미터를 줄이면서 터보 부호의 성능을 증가하도록 하는 터보 오토인코더 기법[7]이 제안되었다. 본 논문에서는 기존 터보 오토인코더의 구조를 개선하여 더욱 향상된 성능을 갖는 모델을 제안한다.

II. 본론

기존 터보 부호의 구조적 특성을 신경망 모델에 반영하여 파라미터 수를 줄인 터보 오토인코더는 1D-CNN 구조를 활용하여 송신부에 2개의 층, 수신부에는 5개의 층으로 신경망 모델이 구성된다. 본 논문에서는 이를 개선하기 위하여 두 가지 전략으로 모델을 수정하였다. 첫 번째는 기본 CNN 대신 특징 추출에 효과적인 DenseNet을 사용하였다. 두 번째는 송신부 신경망 층의 수를 수신부와 동일하게 5개로 증가시켰다.

다음 그림 1과 그림 2는 각각 터보 부호의 송수신기 구조와 제안한 터보 오토인코더의 송수신기 구조를 나타낸 것이다.




그림 1. 터보 부호의 송수신기 구조




그림 2. 제안한 터보 오토인코더의 송수신기 구조

일반적인 오토인코더에서는 인코더 학습과 디코더 학습이 한 에포크 내에서 동시에 수행된다. 그러나 터보 오토인코더에서는 매 에포크마다 부호기 부분을 일정 횟수만큼 학습시킨 후 복호기 부분을 일정 횟수만큼 학습시키는 순차적 학습 방법을 사용한다. 이를 통해 제안한 시스템이 학습 과정에서 로컬 미니멈 값에 빠지는 현상을 막을 수 있다.

다음 표는 제안한 터보 오토인코더의 학습에 사용된 하이퍼 파라미터를 나타낸 것이다.

파라미터	설정값
손실함수	이진 교차엔트로피
부호기 블록	5층 1D-DenseNet, 필터 크기=5, 필터 개수=100
복호기 블록	5층 1D-DenseNet, 필터 크기=5, 필터 개수=100
복호 반복 횟수	6
정보 특성 크기	5
배치 크기	500~2000
최적화 방법	Adam, 학습률=0.0001
학습 방법	에포크 당 부호기 100번 학습 후 복호기 500번 학습 부호기 학습 SNR=2dB, 복호기 학습 SNR=-1.5~2dB
정보 블록 크기	40
에포크 수	400

앞서 소개한 두 가지 전략을 적용한 터보 오토인코더를 위와 같은 하이퍼 파라미터 환경에서 실험하였다. 그림 3과 그림4는 기존 터보 오토인코더, 전략 1만을 적용한 터보 오토인코더, 전략 2만 적용한 터보 오토인코더, 그리고 전략 1과 전략 2를 함께 적용한 터보 오토인코더의 성능을 각각 블록 오류율과 비트 오류율 관점에서 비교한 것이다. 이 결과를 통해 제안한 전략이 모두 성능 개선 효과가 있으며, 두 전략을 모두 적용한 모델이 가장 우수한 성능을 가짐을 실험을 통해 확인하였다.

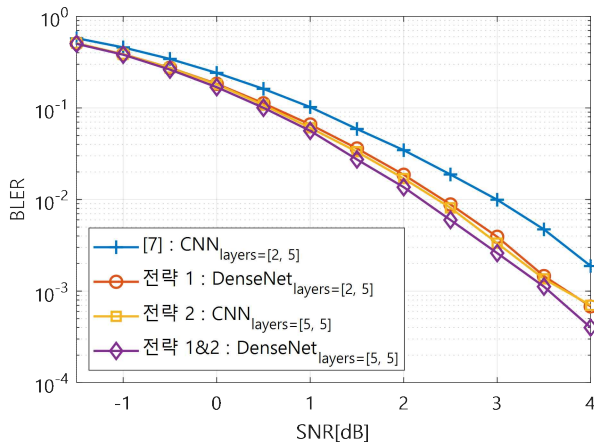


그림 3. 터보 오토인코더의 블록 오류율 성능 비교




그림 4. 터보 오토인코더의 비트 오류율 성능 비교

III. 결론

본 논문에서는 딥러닝 기반의 오류정정부호의 하나인 터보 오토인코더의 구조를 개선하여 성능을 향상시키는 기법을 제안하였다. 입력 데이터의 특징 추출을 더욱 효과적으로 수행하는 신경망을 적용하고 계층을 깊게 하여 성능 이득을 얻는 전략을 취하였다. 향후 추가 개선을 위하여 파라미터 수의 증가로 복잡도가 지수적으로 증가하지 않는 범위 내에서 특징 추출에 효과적인 다양한 신경망 구조를 고려할 수 있다.

참 고 문 헌

- [1] M. Zhang, Q. Huang, S. Wang, and Z. Wang, "Construction of LDPC Codes Based on Deep Reinforcement Learning," *IEEE International Conference on Wireless Communications and Signal Processing*, Oct. 18-20, 2018.
- [2] Y. Liao, S. A. Hashemi, J. Cioffi, and A. Goldsmith, "Construction of Polar Codes with Reinforcement Learning," *IEEE Global Communications Conference*, Dec. 7-11, 2020.
- [3] S. Zhang, S. Chen, and X. Yang, "LEARN Codes: Inventing Low-Latency Codes via Recurrent Neural Networks," *IEEE J. Sel. Areas Inf. Theory*, vol. 1, no. 1, pp. 207-216, May 2020.
- [4] E. Nachmani, E. Marciano, L. Lugosch, W. J. Gross, D. Burshtein, and Y. Be'ery, "Deep Learning Methods for Improved Decoding of Linear Codes," *IEEE J. Sel. Topics Signal Process.*, vol. 12, no. 1, pp. 119-131, Feb. 2018.
- [5] S. Habib, A. Beemer, and J. Kliewer, "Learned Scheduling of LDPC Decoders Based on Multi-armed Bandits," *IEEE International Symposium on Information Theory*, Jun. 21-26, 2020.
- [6] S. Dörner, S. Cammerer, J. Hoydis, and S. t. Brink, "Deep Learning Based Communication Over the Air," *IEEE J. Sel. Topics Signal Process.*, vol. 12, no. 1, pp. 132-143, Feb. 2018.
- [7] H. Kim, S. Oh, and P. Viswanath, "Physical Layer Communication via Deep Learning," *IEEE J. Sel. Areas Inf. Theory*, vol. 1, no. 1, pp. 5-18, May 2020.