

딥러닝 기반 다차원 변조 송수신기 성능 분석

임수빈, 박예린, 김정현

순천향대학교

qlstn9150@gmail.com, 0003025@naver.com, kimjh@sch.ac.kr

Performance analysis of deep learning-based multi-dimensional transceiver

Subeen Leem, Yelin Park, Junghyun Kim

Soonchunhyang Univ.

요약

본 논문은 딥러닝 기반 다차원 변조 송수신기의 성능을 비교하고 분석한다. 기존 컨벌루션 신경망 구조의 다차원 변조 송수신기는 좋은 성능을 갖지만 많은 학습 파라미터가 존재하여 블록 길이가 길어질수록 매우 높은 복잡도를 갖는다. 따라서 게이트 순환 유닛층을 활용하여 적은 수의 학습 파라미터만으로 기존 구조의 성능에 근접하는 새로운 신경망 구조의 모델을 제안하였다.

I. 서론

딥러닝 기반의 송수신기 설계[1-4]는 6G 이동통신을 위한 후보 기술 중 하나로 주목받고 있다. 단순한 dense neural network (DNN) 기반 오토인코더 구조의 송수신기 모델[1-2]이 제안된 이후 고도화된 DNN 기반 오토인코더 구조의 송수신기 모델[3]이 제안되었고, 최근 convolutional neural network (CNN) 기반 오토인코더 구조의 송수신기 모델인 AE-CNN[4]이 제안되었다. 본 논문에서는 CNN 기반 오토인코더 구조의 송수신기 모델의 성능에 근접하면서 복잡도를 현저하게 낮춘 새로운 신경망 구조의 송수신기 모델인 AE-CNN&GRU를 제안한다.

II. 본론

본 논문에서는 기존에 제안된 다양한 구조의 오토인코더 중 CNN 기반 오토인코더 구조의 송수신기 모델인 AE-CNN[4]을 비교 대상으로 한다. AE-CNN의 기본 구조는 그림 1과 같다. 즉, 송신기는 3개의 1차원 CNN 층으로 구성되고 수신기도 3개의 1차원 CNN 층으로 구성된다. 반면, 제안하는 AE-CNN&GRU의 기본 구조는 그림 2와 같다. 송수신기 모두 1차원 CNN 층 1개와 gated recurrent unit (GRU) 층 1개로 구성된다. 단, 송신기와 수신기가 대칭형 구조를 이루고 있다. 여기서 CNN 층은 시계열 데이터의 지역적 특징을 추출하고 GRU는 좀 더 넓은 영역의 특징을 추출하기 위해 사용된다. 이러한 효율적인 구조를 통해 높은 성능과 낮은 복잡도를 동시에 얻을 수 있다.




그림 1. AE-CNN 송수신기의 구조




그림 2. 제안하는 AE-CNN&GRU 송수신기의 구조

성능 비교를 위하여 정보 비트를 4비트, 부호어 길이를 8비트, 그리고 4개의 복소 채널 사용을 가정하였다. 학습 환경에서의 잡음은 7dB로 랜덤하게 발생시켰다. 반복 학습을 위한 에포크 수는 200회로 하고 Adam 최적화기를 학습률 0.001로 설정하여 사용하였다. 그림 3은 기존 모델인 AE-CNN과 제안하는 모델인 AE-CNN&GRU의 성능을 비교한 것이다. 제안한 모델이 단순한 구조를 사용함으로써 학습 소요 시간과 테스트 소요 시간을 현저하게 줄일 수 있으나 심볼 오류율 성능이 다소 열화됨을 확인할 수 있었다.




그림 3. AE-CNN 송수신기와 제안하는 AE-CNN&GRU 송수신기의 성능 비교

참 고 문 헌

표 1과 표 2는 각각 기존 모델인 AE-CNN의 파라미터 수와 제안하는 모델인 AE-CNN&GRU의 파라미터 수를 나타낸 것이다. 기존 모델 대비 제한하는 기법의 전체 파라미터 수가 약 41%로 감소하였음을 확인할 수 있다. 이러한 파라미터 수 감소는 학습 소요 시간과 테스트 소요 시간을 줄여줄 뿐만 아니라 모델 학습 시 파라미터들이 빠르고 안정적으로 수렴할 수 있도록 한다.

표 1. AE-CNN 송수신기의 층별 파라미터 수

Layer (type)	Output Shape	Param #
conv1d (Conv1D)	(None, 8, 256)	4352
batch_normalization (Batch Normalization)	(None, 8, 256)	1024
activation (Activation)	(None, 8, 256)	0
conv1d_1 (Conv1D)	(None, 8, 256)	65792
batch_normalization_1 (Batch Normalization)	(None, 8, 256)	1024
activation_1 (Activation)	(None, 8, 256)	0
conv1d_2 (Conv1D)	(None, 8, 8)	2056
batch_normalization_2 (Batch Normalization)	(None, 8, 8)	32
activation_2 (Activation)	(None, 8, 8)	0
power_norm (Lambda)	(None, 8, 8)	0
channel_layer (Lambda)	(None, 8, 8)	0
conv1d_3 (Conv1D)	(None, 8, 256)	2304
batch_normalization_3 (Batch Normalization)	(None, 8, 256)	1024
activation_3 (Activation)	(None, 8, 256)	0
conv1d_4 (Conv1D)	(None, 8, 256)	65792
batch_normalization_4 (Batch Normalization)	(None, 8, 256)	1024
activation_4 (Activation)	(None, 8, 256)	0
conv1d_5 (Conv1D)	(None, 8, 16)	4112
Total params: 148,536		
Trainable params: 146,472		
Non-trainable params: 2,064		

표 2. 제안하는 AE-CNN&GRU 송수신기의 층별 파라미터 수

Layer (type)	Output Shape	Param #
conv1d_6 (Conv1D)	(None, 8, 128)	2176
batch_normalization_5 (Batch Normalization)	(None, 8, 128)	512
activation_5 (Activation)	(None, 8, 128)	0
gru (GRU)	(None, 8, 8)	3288
power_norm (Lambda)	(None, 8, 8)	0
channel_layer (Lambda)	(None, 8, 8)	0
gru_1 (GRU)	(None, 8, 128)	52608
conv1d_7 (Conv1D)	(None, 8, 16)	2064
Total params: 60,648		
Trainable params: 60,392		
Non-trainable params: 256		

III. 결론

본 논문에서는 기존의 높은 복잡도를 갖는 딥러닝 기반 송수신기 모델인 AE-CNN을 복잡도 측면에서 개선한 AE-CNN&GRU 구조의 송수신기를 제안하였다. 제안한 송수신기는 기존 송수신기 대비 성능 열화를 최소화하면서 복잡도에 영향을 미치는 파라미터 수를 약 41% 정도로 감소시켰다. 이러한 결과를 바탕으로 향후 연구로써 성능 열화와 복잡도를 더욱 낮춘 새로운 신경망 구조의 송수신기 모델 설계를 고려할 수 있다.

- [1] T. O'Shea and J. Hoydis, "An Introduction to Deep Learning for the Physical Layer," *IEEE Trans. on Cogn. Commun. Netw.*, vol. 3, no. 4, pp. 563-575, Dec. 2017.
- [2] S. Dörner, S. Cammerer, J. Hoydis, and S. ten Brink, "Deep Learning based Communication Over the Air," *IEEE J. Sel. Topics Signal Process.*, vol. 12, no. 1, pp. 132-143, Feb. 2018.
- [3] J. Kim, B. Lee, H. Lee, Y. Kim, and J. Lee, "Deep Learning-assisted Multi-Dimensional Modulation and Resource Mapping for Advanced OFDM Systems," in *Proc. IEEE GLOBECOM*, Abu Dhabi, UAE, Dec. 9-13, 2018.
- [4] N. Wu, X. Wang, B. Lin, and K. Zhang, "A CNN-Based End-to-End Learning Framework Toward Intelligent Communication Systems," *IEEE Access*, vol. 7, pp. 110197 - 110204, 2019.